Relatório técnico — Classificação de Síndrome dos Ovários Policísticos

Identificação

- Instituição: Fiap
- Curso: IA para DEVs
- Fase: 1
- Integrante: Brenda Reis - RM376294
- Repositório: https://github.com/brenda-guinarte/pos-fiap-ia-para-devs
- Vídeo: https://youtu.be/rRfgysj36dU
- Data: 29/08/2026

1. Introdução

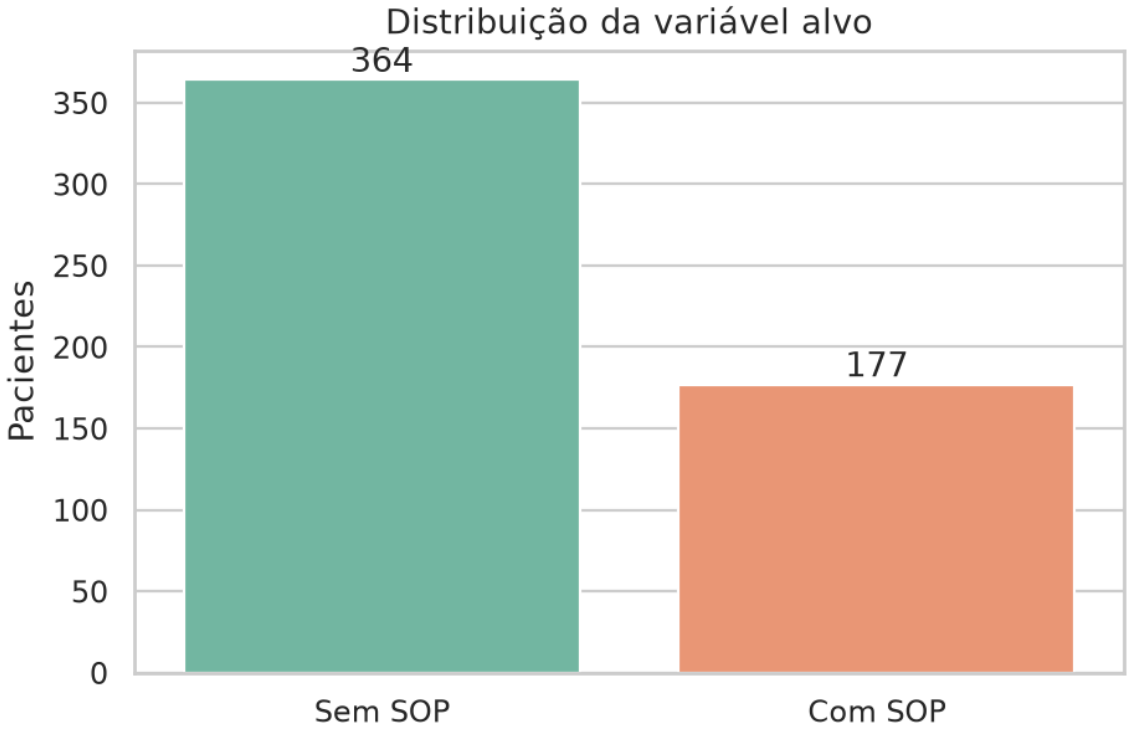
A Síndrome dos Ovários Policísticos (SOP ou PCOS) é uma condição hormonal associada a alterações do ciclo menstrual, sinais de hiperandrogenismo, fertilidade e riscos metabólicos. Este projeto investiga o uso de aprendizado de máquina como apoio à triagem, classificando pacientes em “com SOP” ou “sem SOP” a partir de parâmetros clínicos estruturados.

O objetivo não é substituir a avaliação profissional. O sistema proposto deve funcionar como um sinalizador de risco para apoiar a priorização de pacientes, mantendo a decisão diagnóstica com a equipe médica.

2. Dados

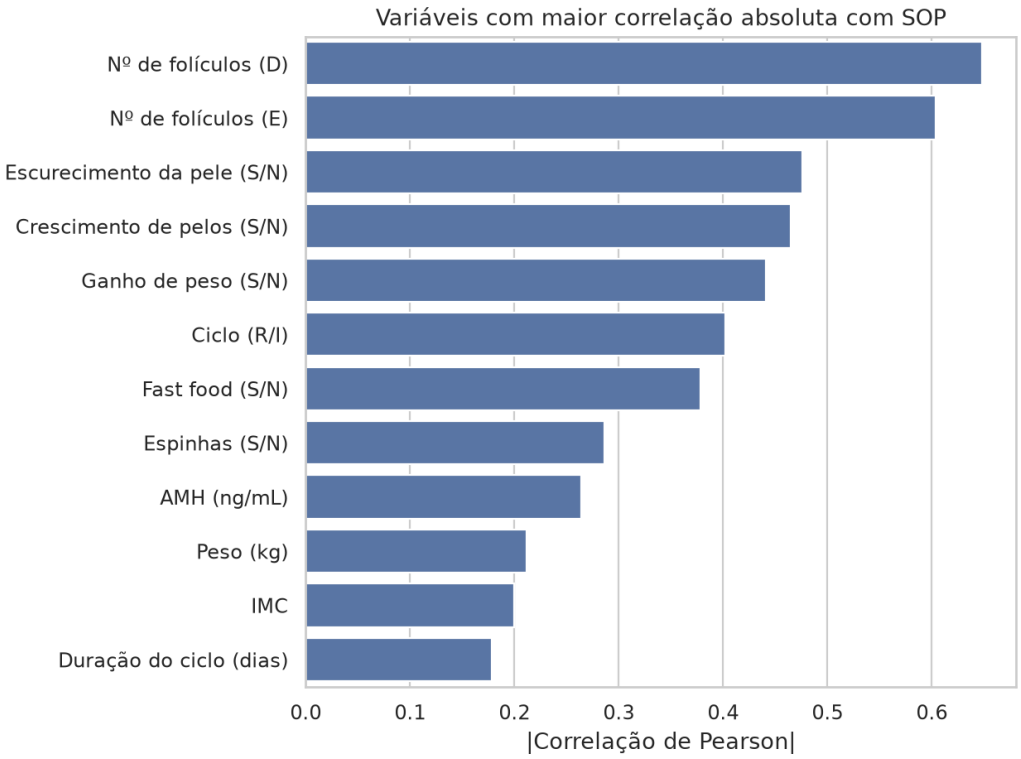
Foi utilizado o dataset público
Polycystic ovary syndrome (PCOS),
publicado por Prasoon Kottarathil em 2020. A base reúne parâmetros físicos e clínicos de 541 pacientes atendidas em dez hospitais de Kerala, Índia.

A variável alvo é `SOP (S/N)`, codificada como 0 para ausência e 1 para presença de SOP. Identificadores administrativos foram removidos por não terem significado preditivo e poderem introduzir relações artificiais. As demais colunas clínicas foram traduzidas para português no pipeline de carregamento.



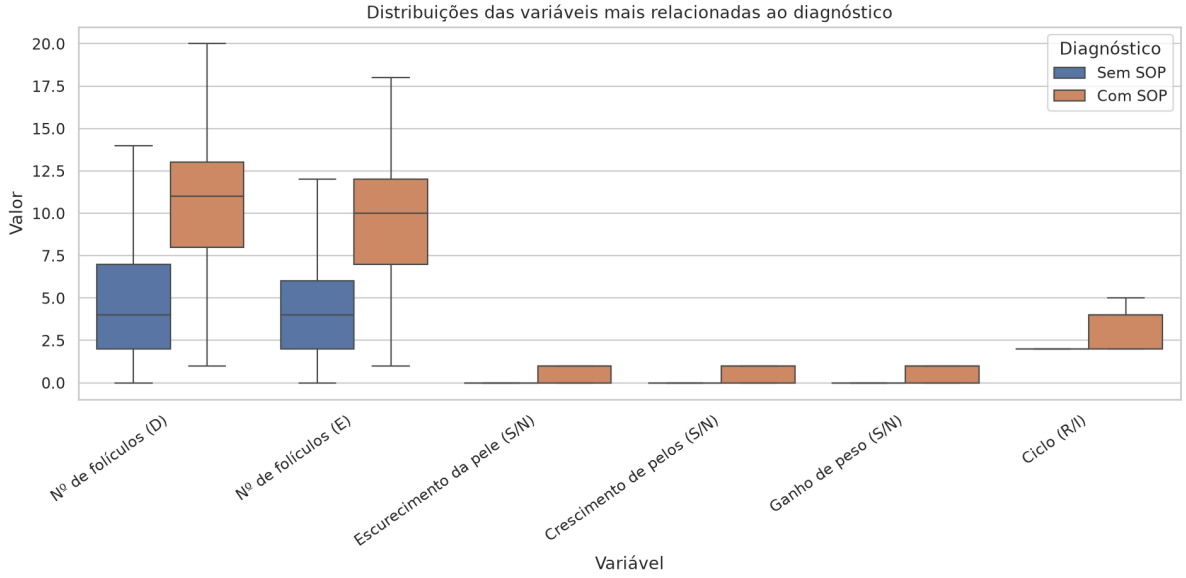
3. Análise exploratória

A exploração verificou dimensões, tipos, estatísticas descritivas, valores ausentes, duplicidades, distribuição da classe alvo e relação das variáveis com o diagnóstico.



As correlações são descritivas e não implicam causalidade. Variáveis com maior associação podem refletir critérios já usados na investigação da SOP. Essa

característica favorece a predição no contexto do dataset, mas exige cautela ao definir o momento clínico em que o modelo seria utilizado.



Das 541 pacientes, 177 pertencem à classe com SOP, correspondendo a 32,7% da amostra. O desbalanceamento é moderado e foi tratado com estratificação e pesos de classe, sem criação de observações sintéticas.

As maiores correlações positivas com o alvo foram número de folículos no ovário direito (0,648), número de folículos no ovário esquerdo (0,603), escurecimento da pele (0,476), crescimento de pelos (0,465), ganho de peso (0,441) e irregularidade do ciclo (0,402). Esses padrões são clinicamente plausíveis: diretrizes internacionais relacionam o diagnóstico em adultas à disfunção ovulatória, hiperandrogenismo e morfologia policística dos ovários, depois da exclusão de outras causas.

Quatro campos possuem apenas um valor ausente cada (0,18%): tempo de casamento, segundo beta-HCG, AMH e consumo de fast food. A variável AMH também continha uma entrada textual inválida, convertida em ausente. Uma coluna residual sem significado clínico, com apenas dois valores espúrios, foi removida.

4. Pré-processamento

Foram aplicadas as seguintes etapas:

1. Remoção de número sequencial, número de prontuário e coluna residual.
2. Conversão de campos clínicos para formato numérico, transformando entradas inválidas em ausentes.
3. Imputação pela mediana nas variáveis numéricas.
4. Imputação pela moda e One-Hot Encoding nas categorias codificadas de grupo sanguíneo e regularidade do ciclo.
5. Padronização das variáveis numéricas.

As transformações foram encapsuladas em um `ColumnTransformer` dentro de cada pipeline. Elas são ajustadas somente com o conjunto de treino, evitando vazamento de informações do teste.

5. Estratégia de modelagem

Foi realizada separação estratificada de 80% para treino e 20% para teste com semente fixa 42. No treino, foi aplicada validação cruzada estratificada com cinco folds.

Dois modelos foram comparados:

- **Regressão Logística:** baseline linear, eficiente e interpretável por coeficientes.
- **Random Forest:** conjunto de árvores capaz de aprender interações e relações não lineares, com importância de variáveis disponível.

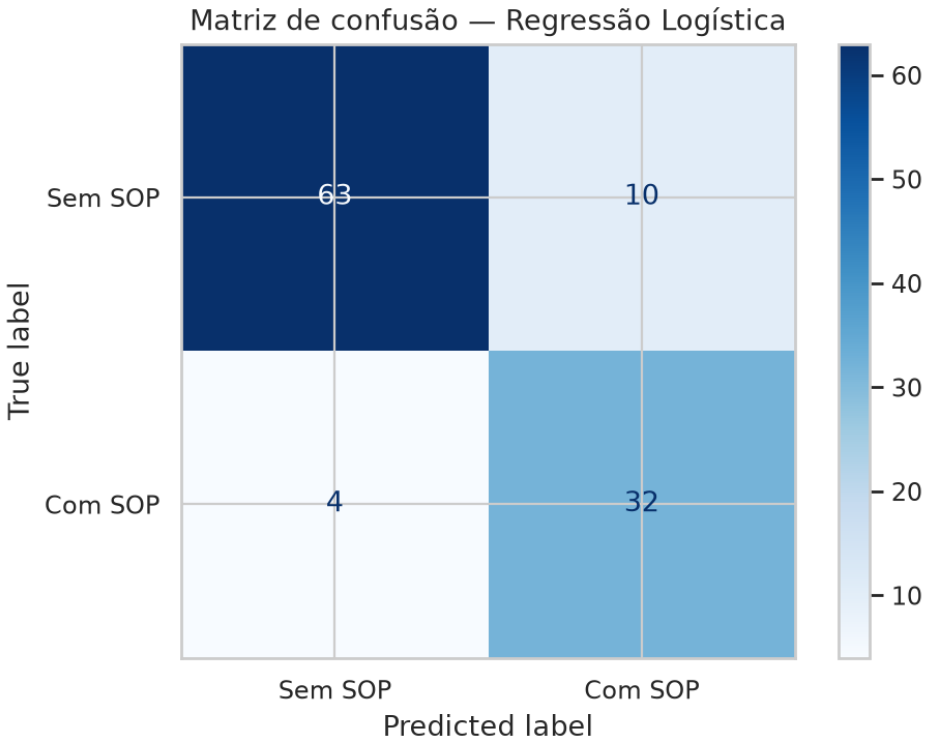
Os dois modelos utilizam pesos balanceados para reduzir o impacto da diferença entre as classes.

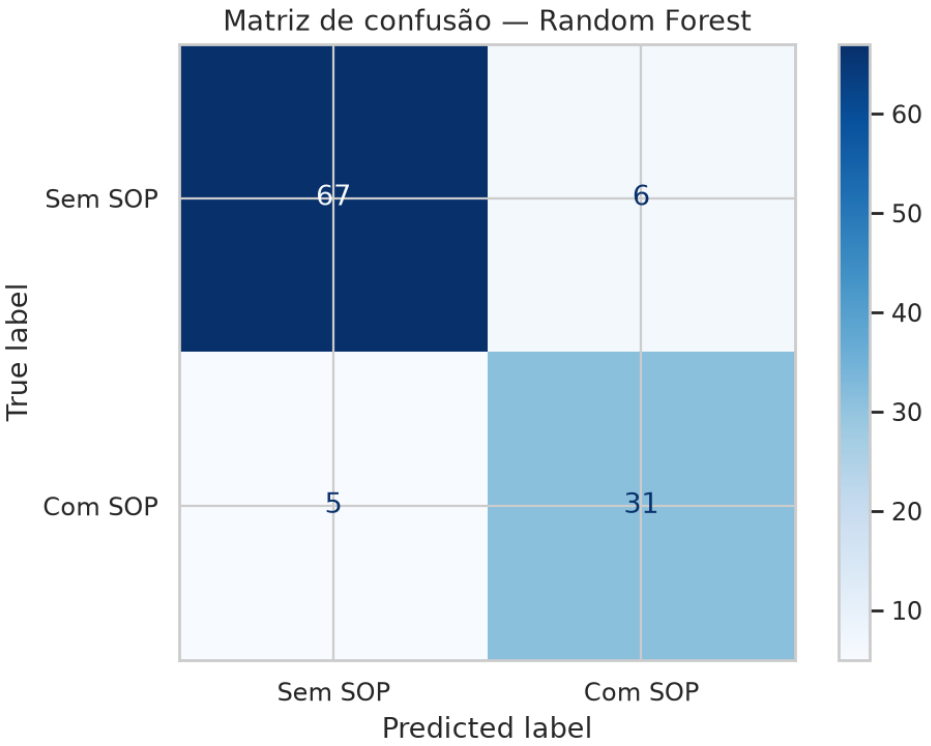
6. Métricas e critério de escolha

Foram avaliadas accuracy, precisão, recall, F1 e ROC-AUC. A principal métrica foi o **recall da classe positiva**, pois um falso negativo pode atrasar a investigação de uma paciente com possível SOP. O F1 complementa a análise ao equilibrar recall e precisão, enquanto ROC-AUC mede a capacidade geral de separação entre as classes.

Modelo	Accuracy	Precisão	Recall	F1	ROC-AUC
Regressão Logística	0,872	0,762	**0,889**	0,821	**0,951**
Random Forest	**0,899**	**0,838**	0,861	**0,849**	0,941

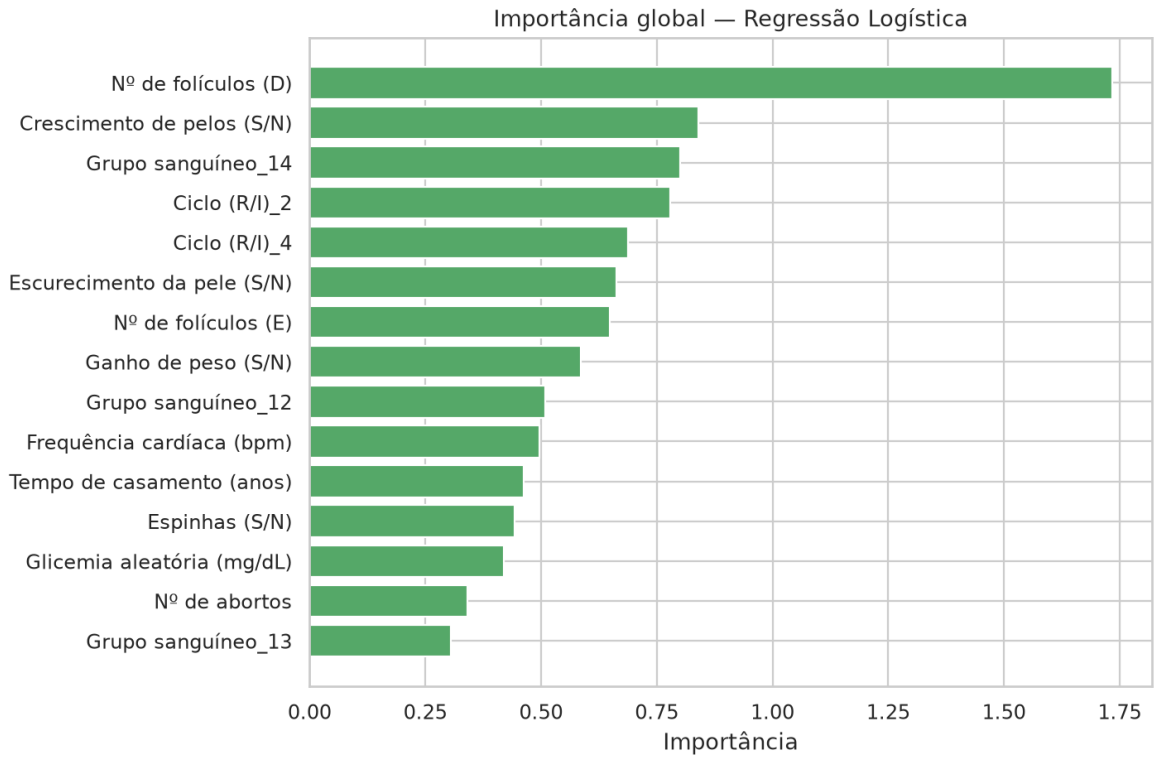
Pelo critério definido previamente, a Regressão Logística foi selecionada por obter o maior recall no conjunto de teste. Embora a Random Forest apresente melhores accuracy, precisão e F1, o modelo linear deixou de identificar menos casos positivos nesta divisão.



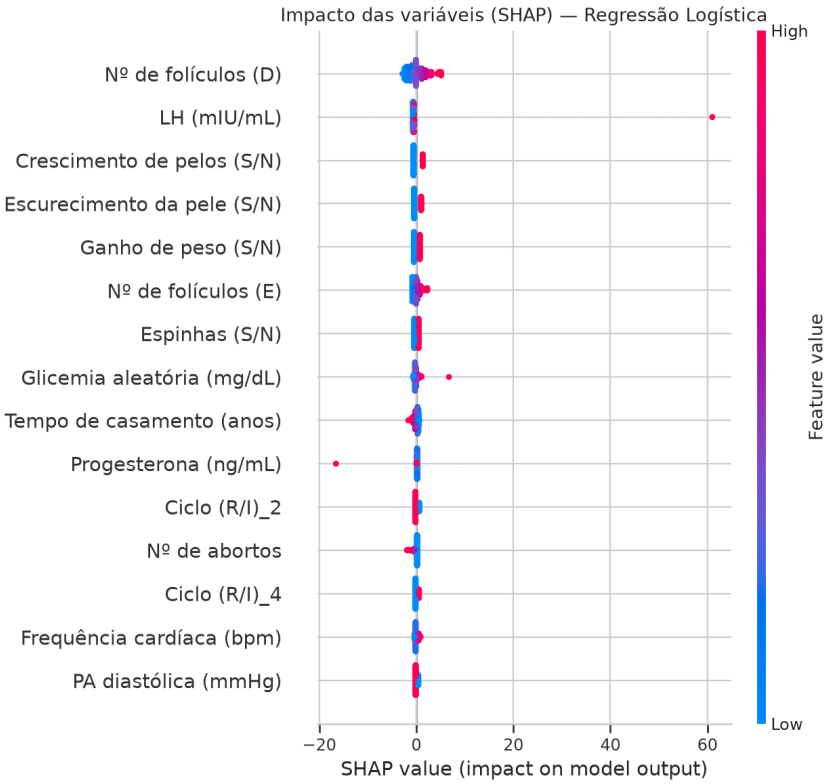


7. Explicabilidade

A importância global permite observar quais variáveis mais influenciam o modelo. Valores altos de importância indicam contribuição preditiva, não uma relação causal.



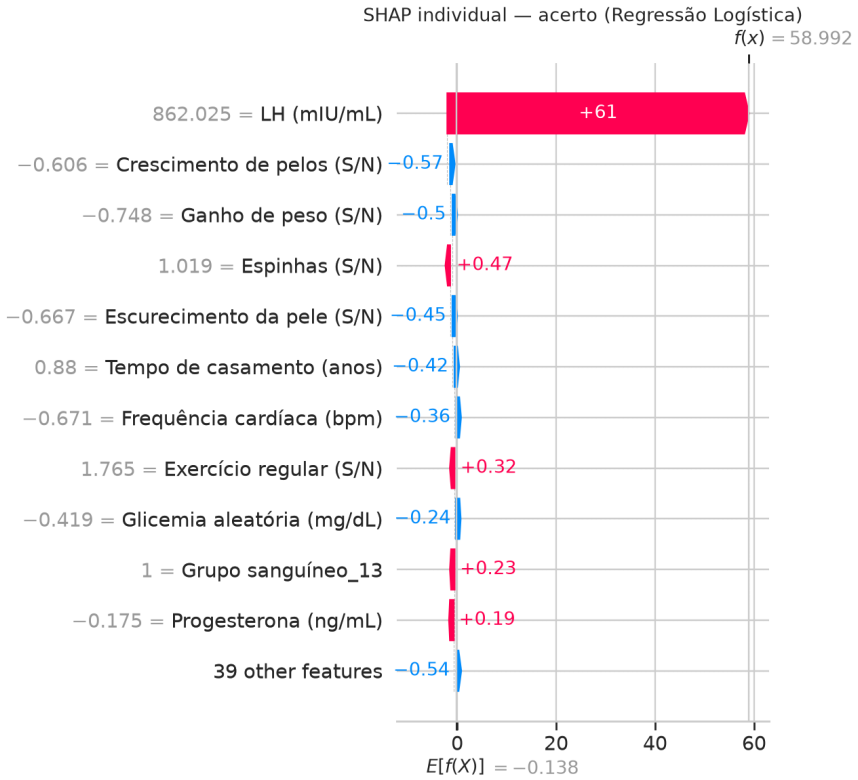
O SHAP mostra direção e intensidade da contribuição das variáveis em diferentes pacientes. Pontos à direita aumentam a saída do modelo; pontos à esquerda a reduzem. A interpretação deve considerar o significado clínico e a forma como as variáveis foram transformadas.

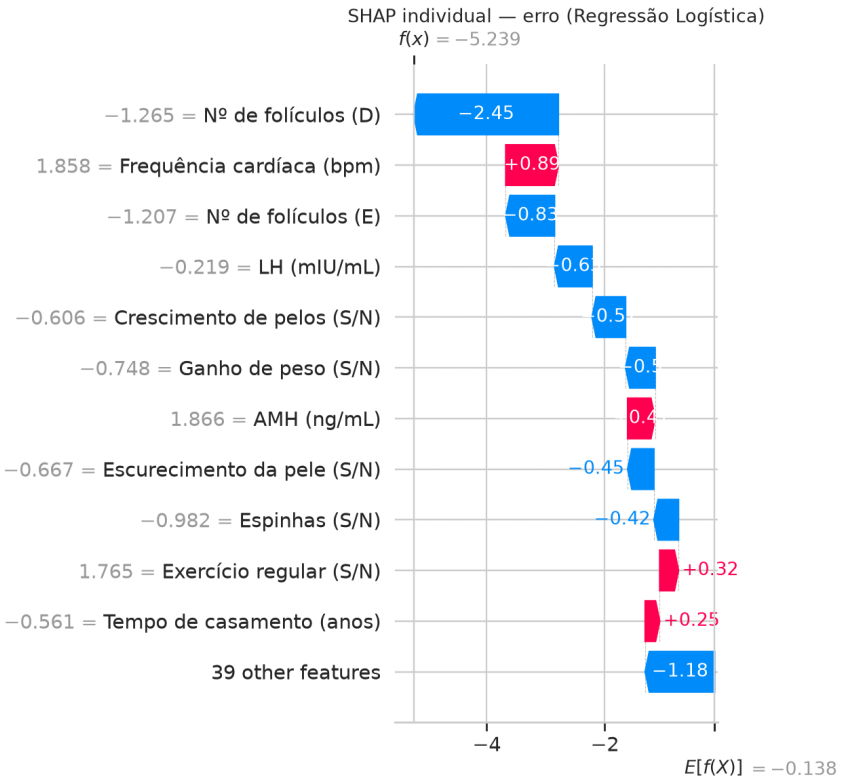


No modelo selecionado, as maiores magnitudes globais ocorreram para número de folículos no ovário direito, crescimento de pelos, categorias de grupo sanguíneo, regularidade do ciclo, escurecimento da pele, número de folículos no ovário esquerdo e ganho de peso. Folículos, irregularidade menstrual e sinais

de hiperandrogenismo são coerentes com os critérios diagnósticos descritos pela OMS e pela diretriz internacional de 2023. Já a aparente influência de categorias de grupo sanguíneo não deve ser interpretada como causal: pode ser instabilidade de uma amostra pequena e deve ser investigada em validação externa.

Foram selecionados dois casos anônimos no conjunto de teste: a Paciente A, classificada corretamente, e a Paciente B, com erro de classificação (preferencialmente falso negativo). Os gráficos waterfall correspondentes preservam o anonimato e descrevem o comportamento do modelo, não uma justificativa clínica.





8. Discussão crítica

Os resultados sugerem que os dados contêm padrões úteis para classificação, mas não justificam uso clínico imediato. A base possui apenas 541 registros e representa hospitais de uma região específica da Índia. Diferenças de população, protocolo, equipamentos e preenchimento podem reduzir o desempenho em outro contexto.

Antes de uso prático seriam necessários:

- validação externa, preferencialmente em população brasileira;
- calibração das probabilidades e definição clínica do limiar;
- avaliação de desempenho por faixa etária e outros subgrupos;
- análise de viés, drift e qualidade dos dados;
- integração com fluxo de revisão humana;
- controles de privacidade, segurança e LGPD.

O uso mais apropriado seria como apoio à triagem: pacientes com risco elevado seriam priorizadas para avaliação, sem produção de diagnóstico automático.

9. Conclusão

O projeto demonstrou um fluxo reproduzível de exploração, pré-processamento, treinamento, avaliação e explicabilidade para classificação de SOP. A Regressão Logística foi selecionada pelo maior recall, alinhado ao custo de falsos negativos. Os resultados são promissores no contexto acadêmico, porém dependem de validação externa e supervisão médica antes de qualquer aplicação real.

10. Referências

- KOTTARATHIL, Prasoon. *Polycystic ovary syndrome (PCOS)*. Kaggle, 2020. Disponível em: https://www.kaggle.com/datasets/prasoonkottarathil/polycystic-ovary-syndrome-pcos
- WORLD HEALTH ORGANIZATION. *Polycystic ovary syndrome*. Disponível em: https://www.who.int/news-room/fact-sheets/detail/polycystic-ovary-syndrome
- TEEDE, H. J. et al. Recommendations From the 2023 International Evidence-based Guideline for the Assessment and Management of Polycystic Ovary Syndrome. *The Journal of Clinical Endocrinology & Metabolism*, v. 108, n. 10, p. 2447–2469, 2023. DOI: https://doi.org/10.1210/clinem/dgad463